



MODEL CAPACITY MARKET

期算白皮书

发布日期

2026年7月24日

版本

v2.0

目录

部分	内容	页码	部分	内容	页码
00	阅读说明	3	01	执行摘要	4
02	市场背景	6	03	KAI 的定位与产品定义	8
04	产品价值	10	05	市场参与者	13
06	市场全生命周期	15	07	GLM-5.2 示例	17
08	定价与市场结构	20	09	商业模式	22
10	治理与风险管理	24	11	市场进入与发展路线	26
12	竞争壁垒与网络效应	28	13	结论	30
14	附录：术语表	31			

阅读说明

白皮书边界与术语

文件定位

本白皮书提出 KAI 模型服务容量市场的概念框架，重点阐述产品价值、参与者关系、市场运行、商业模式、治理体系及落地路径。文中不讨论底层系统架构、接口协议、算力调度算法、模型部署方案或其他技术实现细节。

示例说明

- 除非另有说明，所有机构、交易价格、合同参数和业务案例均为示例。

术语约定

术语	本白皮书中的含义
模型服务容量	在约定交割小时和区域内，使用指定模型提供符合基本交付标准的推理服务能力。
TPM	Tokens Per Minute，每分钟加权 Token 负载。在平台时钟划分的每个连续、互不重叠的 60 秒计量窗口内，公式为 $TPM = I + W \times O$ 。 I 为该窗口内经平台确认计费的输入 Token 数； O 为实际生成并计费的输出 Token 数； W 为由品种规则确定、随计量规则版本固定且合约存续期间不追溯调整的输出权重系数。缓存命中、思考 Token、失败重试以及跨窗口请求的归属和计量方式，以合约生效时适用的计量规则为准。一手表示在指定交割小时内，每个计量窗口持续可用的 1,000,000 TPM 容量上限，不构成可在一小时内任意集中使用的 60,000,000 Token 余额。
容量买方	为业务连续性、预算确定性或客户服务而采购未来容量的企业。
容量供应商	具备合格模型服务能力并承担交付义务的机构。
交割	在约定小时内向买方提供符合合同标准的模型服务能力。
期算	本白皮书对未来指定交割小时内标准化模型服务容量合约的专用名称，其产品机制以本白皮书所述规则为准。

执行摘要

KAI 解决什么问题，以及为何具有产业价值

一句话定义

KAI 是面向企业的模型服务容量市场；期算将未来指定交割小时内某个确定模型的使用权，变成可采购、可比较、可转让和可履约管理的标准产品；TPM 是基础容量计量指标。

一手容量：

$$1,000,000 \text{ TPM} \times 1 \text{ h}$$

生成式人工智能正在从实验性工具转变为生产系统。企业对模型的要求也随之变化：不再只是“平均价格是多少”或“接口是否可调用”，而是“在关键时间、关键区域、关键业务量下，能否获得确定能力，并把成本控制在预算内”。传统按 Token 付费、按实例租赁或长期包量采购，分别解决了使用计费、底层资源和长期折扣问题，却没有充分解决小时级供需错配、模型特定性、容量不可储存和价格波动等问题。

KAI 是面向企业的模型服务容量市场，“期算”是该市场中面向未来指定交割小时的标准化容量产品。KAI 以 TPM（Tokens Per Minute，每分钟 Token 负载）为基础容量计量指标：

$$\text{TPM} = I + W \times O$$

其中， I 、 O 分别为每分钟输入和输出 Token 数， W 由 KAI 在品种规则中统一规定并公开。合约以 $\text{TPM} \cdot \text{h}$ 表示容量与持续时间；一手代表指定交割小时内每个计量窗口持续可用的 1,000,000 TPM 容量上限。

KAI 统一约定模型及版本、上下文上限、每手容量、交割小时、区域、超额处理方式和基本交付标准，使不同供应商提供的同一品种具备可比较、可转让和可交割性。单次请求超过统一上下文上限时直接拒绝；聚合 TPM 超过所持容量时默认拒绝新增请求，合同另有约定的，可采用排队、降速或实时补购。

容量供应商提前登记可交付能力，企业买方提前锁定未来使用权；在交割前，持有者可以依规则转让；交割小时结束前已被系统接受的请求按其所属交割小时继续完成，窗口结束后不再接受新请求，未使用容量归零。

本白皮书的七项核心判断

1. AI 容量的经济价值正从“拥有多少芯片”转向“在何时、何地、以何种模型质量提供多少可用服务”。
2. 小时级使用权最接近企业业务事件的真实需求，也最能反映容量不可储存、峰谷差异显著的特征。
3. KAI 的首要价值不是增加金融杠杆，而是建立标准、提高履约确定性、形成透明价格并改善资源配置。

- 4. 买方通过 KAI 获得容量保障、价格确定性和跨供应商采购能力；供应商获得销售前置、收入确定性、利用率提升和更清晰的扩容信号。
- 5. 开放权重且可由多家机构运营的模型，更适合作为早期标准化品种；GLM-5.2 的公开模型资料可用于说明多供应商交割的概念可能性。
- 6. KAI 应从买方向平台全额预付、供应商提供履约担保、面向企业的期算预订与转让市场起步，在形成可靠现货交付和价格指数后，再逐步扩展产品形态。
- 7. 市场的长期壁垒来自可交割标准、供应商网络、买方流动性、信用治理和历史数据，而不是单一撮合软件。

KAI 的目标结果

目标	市场改变
让容量可见	把分散在不同供应商、不同区域和不同时段模型服务能力转换为统一可比较的产品。
让风险可管理	让买方提前锁定成本与能力，让供应商提前锁定收入与利用率。
让交付可追责	通过统一合同、资格管理和违约规则，把服务承诺转化为可执行责任。
让价格可发现	用真实买卖需求形成不同模型、区域和时间的容量价格曲线。
让生态可扩展	为聚合商、保险、独立评估、指数、融资和跨区域采购创造标准基础。

市场背景

AI 采购从按量调用走向时间确定的容量保障

2.1 企业需求正在从“调用权”转向“确定性”

在模型应用的早期阶段，企业通常以少量试用、按量付费和弹性调用为主。进入生产阶段后，需求具有更强的时间性：电商大促、在线教育开课、游戏版本发布、客服高峰、批量内容生产、代码代理集中运行、金融和制造业的日终处理，都可能在短时间内形成明确的容量峰值。

此时，单纯知道模型单价并不足够。企业更关心四项确定性：第一，关键时段是否有容量；第二，成本是否超出预算；第三，服务质量是否一致；第四，供应商失败后是否有替代安排。KAI 的产品价值来自同时处理这四个问题。

2.2 模型服务容量具有四个结构性特征

特征	经济含义	对市场设计的要求
不可储存	本小时未使用的服务能力无法留到下小时出售。	需要分时价格、临近交割转让和实时平衡机制。
时间敏感	同一模型在工作日高峰与夜间的价值不同。	合约必须明确日期和小时，并形成峰谷价格曲线。
模型特定	企业通常不能在关键业务中随意替换模型。	标的应固定模型或严格定义可替代模型等级。
质量相关	相同 Token 数并不代表相同业务价值。	标准必须固定模型及版本、统一上下文上限、交割区域和基本交付责任。

2.3 现有采购方式的不足

全球云服务商已经提供面向稀缺计算资源的未来容量预订。AWS Capacity Blocks for ML 允许企业提前锁定机器学习计算容量，定价受供需影响并在预订时收费；Google Cloud 的未来预订用于提前获得重要或稀缺资源的容量保障。这些产品验证了“未来容量具有独立商业价值”，但通常仍局限于单一云平台、底层机器资源和不可连续交易的采购关系。

方式	主要优点	主要不足
按 Token 付费	简单、弹性高、适合不确定需求。	通常不保证特定高峰时段容量，预算随实际负载变化。

方式	主要优点	主要不足
按实例或 GPU 租赁	对底层资源控制较强。	企业需自行承担模型运营，且不同硬件难以直接比较业务产出。
长期包量合同	可获得折扣和稳定合作关系。	灵活性低，难以针对某个小时转让或调整。
单云容量预订	能提高特定资源的可获得性。	供应商封闭、缺少跨平台价格发现和统一交割标准。
KAI 期算（TPM·h）	面向业务结果定义容量，支持多供应商、分时采购和标准履约。	需要建立标准、质量评估、流动性和交付框架。

2.4 为什么按小时切分

小时粒度是业务可用性与市场流动性之间的折中。分钟级产品过于碎片化，月度产品又无法表达峰谷差异。小时合约既能覆盖直播、客服、批处理和代理任务等典型场景，也能通过连续小时组合形成四小时、工作时段、夜间或全天产品。

市场判断

KAI 并不是把 GPU 小时换一个名字，而是把“特定模型在特定时段的可用服务能力”从供应商内部能力，转化为企业可以计划 and 管理的采购资产。

KAI 的定位与产品定义

平台边界、核心产品 and 设计原则

3.1 平台定位

KAI 的定位是中立的模型服务容量市场基础设施。平台连接模型发布方、容量供应商、企业买方、聚合商、经纪与风险服务机构，以统一规则组织产品准入、容量登记、交易转让、履约管理和市场信息发布。

KAI 提供统一 API、交易组织、容量路由、计量和交割管理；各容量供应商对其成交并被分配的交付手数承担主要交付责任。除另行购买平台保障服务外，KAI 负责协调替代交付，但不替代成功作无条件保证。

KAI 不应以“自己拥有最多算力”为核心竞争逻辑。若平台同时作为主要自营交易方、唯一供应商和争议裁决方，将削弱市场信任。更稳健的定位是规则制定、资格组织、市场运营和交付治理，并对关联交易进行严格隔离。

3.2 核心产品：按加权 TPM 计量的期算

期算以 TPM（Tokens Per Minute，每分钟 Token 负载）作为基础容量计量指标。在平台时钟划分的每个连续、互不重叠的 60 秒计量窗口内，TPM 定义为：

$$TPM = I + W \times O$$

其中， I 为该窗口内经平台确认计费的输入 Token 数， O 为该窗口内实际生成并计费的输出 Token 数。权重 W 由品种规则确定并随规则版本固定，合约存续期间不追溯调整。

缓存命中、思考 Token、失败重试及跨窗口请求的计量方式由计量细则规定。一手表示在指定交割小时内，每个计量窗口持续可用的 1,000,000 TPM 容量上限，不构成可在一小时内任意集中使用的 60,000,000 Token 余额。持有 N 手时，容量上限为：

$$C_{\max}(N) = N \times 1,000,000 \text{ TPM}$$

TPM 衡量合约账户在交割小时内的聚合 Token 处理负载，不是可集中提取、跨分钟累计或跨小时结转的 Token 库存。首 Token 延迟从平台确认接收符合合约参数的请求时起，至返回首个输出 Token 时止；其阈值与统计口径由品种规则统一约定。单份期算合约由模型及版本、上下文上限、每手容量、交割小时、区域、超额处理方式和基本交付标准共同定义；基本交付标准包括可用性、系统或 API 错误率、约定首 Token 延迟和 TPM 达成规则，不包括模型输出内容的正确性。

核心合约参数	统一约定
指定模型及版本	交付的模型名称和可验证的固定版本标识。

核心合约参数	统一约定
统一上下文上限	同一品种采用统一的单次请求总上下文上限。
一手容量	1,000,000 TPM。
指定交割小时	指定日期、明确时区的一个连续 60 分钟交割小时。
交割区域	指定服务区域和网络范围。
超额处理方式	单次请求超过统一上下文上限时直接拒绝；聚合 TPM 超过容量上限 $C_{\max}(N)$ 时，默认拒绝新增请求；合同另有约定的，可采用排队、降速或实时补购。
基本交付标准	统一约定可用性、系统或 API 错误率、首 Token 延迟、TPM 达成规则等基本交付标准，不包括模型输出内容的正确性。

随着市场成熟，KAI 可针对同一模型、区域和基本交付标准，发布采用不同统一上下文上限的独立产品；不同上下文上限的产品分别挂牌、定价和交割，不在同一品种内混用。

3.3 产品的经济本质

对买方而言，期算合约是未来容量保障；对供应商而言，它是未来收入承诺。买方在成交或受让时向 KAI 全额预付，KAI 在交割完成前按规则管理预付资金；关闸前可按规则有限转让。交割小时结束且确认供应商完成交付后，KAI 再向供应商结算服务价款。买方可以不使用容量，但只要供应商按约提供可用容量，未使用部分仍不退款。

3.4 KAI 的五项设计原则

- 1. 可交割优先：任何合约首先必须对应真实可提供的模型服务能力。
- 2. 标准简单：早期品种维度越少，越容易形成流动性和共同理解。
- 3. 质量可比：不同供应商交付的同一品种必须具有可接受的替代性。
- 4. 责任清晰：容量不足、质量不符、区域错误和买方超额使用应有明确边界。
- 5. 中立透明：平台规则、供应商资格、价格信息和违约处置应可审查。

3.5 KAI 不交易什么

- 不承诺模型输出一定正确，也不对买方业务收入或经营结果作保证。
- 不把所有 GPU 或芯片视为同质商品，底层资源仅是供应商履约手段。
- 原则上不允许供应商超售或重复登记同一份容量；KAI 不直接干预供应商内部容量调度，但供应商应对全部已售容量承担交割责任，因超售导致无法按约交割的，由供应商自行承担违约责任。
- 不以高杠杆和个人投机交易作为市场启动的主要增长方式。

产品价值

对买方、供应商、模型方与产业生态的价值

价值核心

KAI 把原本分散、不可比较、难以承诺的模型容量，转化为有时间坐标、有质量标准、有价格信号和有责任主体的企业采购产品。

4.1 对企业买方：从“尽力而为”转向“可计划运营”

容量保障

企业可以围绕已知业务事件提前锁定容量，将关键时段的模型服务从普通弹性资源升级为明确交付义务。对于大促、直播、招生、版本发布和集中代理任务，容量保障本身可能比平均 Token 单价更重要。

预算确定性

KAI 将未来服务成本在采购时明确化。企业可以把模型成本纳入活动预算、项目预算和客户报价，减少高峰期临时扩容带来的价格不确定性。对于向下游客户提供固定价格服务的企业，提前锁定模型容量还可以降低毛利波动。

跨供应商采购

统一品种降低了逐家比较供应商报价和合同的成本。企业采购的是符合统一基本交付标准的模型服务容量，而不是分别理解每家供应商的底层硬件和技术栈。供应商发生故障时，KAI 可以依据规则组织替代交付，降低单一供应商依赖。

采购灵活性

当预测变化时，买方可在关闸前出售部分不再需要的未来容量，或补购额外小时。与长期不可转让合同相比，这种安排提高了企业需求调整能力，也促进企业更准确地管理容量预测。

服务责任标准化

KAI 通过统一合约明确“供应商应交付什么、买方可以使用多少、何时构成违约、如何补偿”。这使模型服务从泛化的云服务承诺，转化为与具体业务时段对应的履约责任。

4.2 对容量供应商：把闲置风险转化为可管理收入

销售前置与收入确定性

容量供应商可以提前出售未来时段，锁定未来收入和利用率安排。对自建集群、托管运营商和云服务商而言，这有助于覆盖固定成本、提高未来现金流可预测性，并减少完全依赖即时流量的经营波动。

改善扩容决策

远期价格曲线能够反映市场对不同时间、区域和模型的需求预期。若连续多个未来月份的价格维持高位，供应商可以更有依据地增加资源；若价格长期偏低，则应谨慎扩容或调整模型组合。

扩大客户覆盖

供应商无需逐一建立复杂的企业销售关系，也可以通过 KAI 接触标准化需求。中小供应商若达到统一服务标准，能够与大型云平台在明确服务标准下竞争，降低客户获取成本。

容量和收益管理

模型容量具有类似航空座位、酒店房间和电力的易逝性。KAI 为供应商提供按时段分层定价和提前销售工具，使其能够区分基础负载、峰值负载、备用容量和临近交割容量，提高整体收益管理能力。

4.3 对模型发布方：把模型影响力转化为可计量的服务生态

模型发布方可通过标准服务品种扩大模型的企业采用范围，并获得更可见的市场需求信号。对于开放模型，KAI 可以促进多个运营商提供合格服务；模型发布方也可以通过技术协作、品牌品种或收入分成参与。

- 版本价值可观察：不同模型版本的容量价格和需求曲线，反映企业对其实际业务价值的评价。
- 生态规模可扩大：多供应商交付降低了企业对单一托管渠道的依赖。
- 商业模式可丰富：模型方可从技术支持、官方容量供应或品牌合作中获益。
- 生命周期可管理：新版本建立新品种，旧版本通过透明期限结构逐步退出，减少突然下线对企业的冲击。

4.4 对云服务商和数据中心：获得更清晰的需求信号

传统资源采购往往以实例、芯片或长期合同为单位，难以直接反映某个模型在具体时段的业务价值。KAI 的价格把模型偏好、区域需求和时间稀缺性集中表达出来，使基础设施方能够更准确地安排资源、合作供应商和区域布局。

4.5 对产业中介：形成新的专业服务市场

中介角色	可创造的价值
聚合商	批量采购整手容量，再向中小企业提供更小份额和组合服务。
经纪与采购顾问	帮助企业评估需求、选择期限并管理交割安排。

中介角色	可创造的价值
做市与流动性提供者	在不同时间到达的买卖需求之间提供连续报价和头寸缓冲。
独立评估机构	评估供应商能力、服务一致性和违约事实。
保险与信用增级机构	覆盖极端中断、供应商信用或特定业务连续性风险。
数据与指数服务商	发布模型容量价格指数、峰谷指数、区域价差和供需报告。

4.6 对行业和公共治理：提高资源配置透明度

当容量价格被标准化记录后，行业可以观察不同模型、区域和时段真实稀缺程度。透明价格有助于减少重复囤积、无序扩容和信息不对称，也为产业政策、基础设施规划和应急保障提供更可靠的数据基础。

价值对象	直接收益	长期收益
企业买方	容量保障、成本锁定、灵活转让。	更稳定地将模型嵌入核心业务。
容量供应商	提前销售、提高利用率。	更低收入波动和更理性扩容。
模型发布方	扩大服务覆盖和需求可见性。	形成标准化商业生态。
云与数据中心	获得模型级需求信号。	优化资产配置和区域布局。
产业治理	价格透明、责任清晰。	改善整体算力资源配置效率。

市场参与者

不同身份的动机、责任、收益与风险

KAI 市场不是简单的买卖双方关系，而是一套由模型、服务、交易、交割和治理共同构成的角色网络。各身份可以由同一集团承担，但必须建立利益冲突管理和账户隔离。

身份	参与动机	核心义务	主要收益	主要风险
企业最终用户	锁定未来模型容量与成本。	按合同付款、合理申报需求、遵守使用边界。	业务连续性、预算确定性。	需求预测偏差、未使用容量。
容量供应商	提前销售未来能力，提高利用率。	登记真实容量、按时交付、承担违约责任。	服务收入、利用率提升。	故障、成本上涨、超卖。
模型发布方	扩大模型采用和商业生态。	提供清晰版本信息，管理品牌使用。	服务或生态收益。	版本声誉风险。
聚合商	采购大额容量并拆分给客户。	管理客户配额、信用和超额需求。	批零差价、服务费。	利用率、客户集中和超卖风险。
经纪与采购服务商	代理企业进入市场。	需求分析、订单管理、客户沟通。	经纪与顾问收入。	操作责任。
流动性提供者	连接不同时点的买卖需求。	持续报价、控制头寸和交割资格。	价差和流动性激励。	价格波动和临近交割风险。
KAI 平台	建立标准、组织市场和治理交割。	保持中立、发布规则、管理冲突。	交易、会员、交割与数据收入。	市场诚信、运营和声誉风险。
清算或结算机构	降低对手方信用风险。	管理预付资金、履约担保、交割结算与违约处置。	结算服务收入。	极端违约和流动性压力。
质量评估机构	确认供应商和品种达到服务标准。	独立、可复核地出具判断。	评估服务收入。	判断错误和利益冲突。

5.1 套期保值者与价格交易者的区别

企业买方和容量供应商通常以管理实际经营风险为目的：买方担心价格上涨或容量不足，供应商担心价格下跌或容量闲置。期货市场通常通过套期保值者与承担价格风险的流动性参与者共同形成价格发现。KAI 在早期应优先服务有真实容量需求或真实交付能力的机构，并限制无交割能力的主体持仓进入到期阶段。

5.2 为什么需要聚合商

标准合约的一手容量可能仍大于中小企业的实际需求。聚合商通过批量采购、需求组合和子账户分配，把大额标准品转换为更细的企业服务。聚合商同时承担需求不一致、客户信用和临时补购责任，是连接标准化市场与碎片化终端需求的重要角色。

5.3 平台中立性

KAI 可以设立流动性支持计划，但不宜在缺乏隔离的情况下利用未公开订单、供应商履约数据或客户需求进行自营交易。平台、清算、独立复核和供应业务之间应建立治理边界，以确保所有参与者相信规则不会因平台自身利益而改变。

市场全生命周期

从模型准入到小时交割的完整流程

全流程

模型准入 → 供应商资格 → 容量登记 → 供应商报价
采购/转让 → 交割准备 → 小时服务 → 交付确认/评价

阶段	主要活动	阶段结果
1. 模型准入	KAI 选择适合标准化的模型和版本，明确质量与生命周期规则。	形成可挂牌的模型品种。
2. 供应商资格	供应商证明其具有稳定运营模型、持续交付和承担责任的能力。	进入合格交割供应商名录。
3. 容量登记	供应商申报特定日期、小时和区域的可交付数量，并提供相应担保。	形成真实可售容量。
4. 合约挂牌	KAI 发布指定模型及版本、统一上下文上限、一手 1,000,000 TPM、指定交割小时、交割区域、超额处理方式和基本交付标准。	所有参与者使用同一合同语言。
5. 初始销售	供应商针对特定模型、交割区域、日期和交割小时发布可售手数及单位报价，买方按照有效报价直接采购。	形成供应商报价、成交价格 and 对应持仓。
6. 二级转让	买方需求变化时，可在关闸前出售或补购。	提高采购灵活性和流动性。
7. 交割准备	KAI 根据关闸时点的最终持仓，将交割小时的可调用容量绑定至对应平台交易账户及 API 凭证，并确认各供应商应承担的交付数量。	持仓方可通过 KAI 统一提供的交易所 API 调用已购容量。
8. 小时交付	供应商在约定小时提供符合标准的模型服务。	完成实物服务交割。
9. 交付确认与评价	确认交付比例、替代采购、违约补偿和供应商评分。	完成资金与责任闭环。

6.1 模型准入

KAI 应优先选择企业需求清晰、服务表现可标准化且存在多个潜在供应商的模型。模型版本发生重大变化时，应建立新的合约系列，而不是自动替换既有标的。这样可以保护买方对输出行为和业务适配的预期。

6.2 容量登记

供应商应以未来交割窗口内可持续提供的实际 TPM 为基础登记容量，并自行扣除自有客户占用、计划维护及必要冗余。设扣除后的可持续承诺容量为 C_{net} ，则可登记手数为：

$$N_{\text{reg}} = \left\lfloor \frac{C_{\text{net}}}{1,000,000 \text{ TPM}} \right\rfloor$$

其中， $\lfloor \cdot \rfloor$ 表示向下取整。容量登记是供应商对未来可交付服务能力作出的责任声明，KAI 不直接介入或控制供应商的内部容量调度。原则上不得重复登记或超售；如因超售、调度冲突或其他供应商自身原因无法按约交付，应由供应商自行承担违约责任。KAI 可通过履约担保、历史履约记录、登记额度和抽查等方式进行风险管理，但不因此对供应商的实际交付能力承担保证责任。

6.3 交易与转让

初始销售采用供应商报价机制。供应商根据自身成本、可售容量、交割时段和履约安排，发布单位报价、可售手数及报价有效期；买方可以直接采购。KAI 不统一确定市场成交价格。供应商可在成交前调整或撤回尚未被接受的报价，已经成交的价格和交付义务不受后续报价变化影响。

每项供应商报价至少应包含模型及版本、上下文上限、交割日期及小时、交割区域、可售手数、单位价格、报价有效期以及适用的基本交付标准和计量规则版本。

已成交容量可以在关闸前按照挂牌报价方式转让。转让方发布拟转让手数和转让价格，受让方接受报价后完成转让。二级转让不改变原供应商的交付义务及初始服务价款，仅改变容量使用权的持有人。

6.4 交割准备与关闸

KAI 统一提供交易所 API，并在平台账户体系内将合约持仓与可调用容量关联。关闸后，合约停止转让，KAI 按最终持仓锁定各账户在交割小时内的 API 可调用额度，并向各供应商确认其应承担的交付手数。供应商面向 KAI 统一交付，不接收最终用户身份或终端业务主体分配。

6.5 未使用、超额与违约

- 未使用：买方可以不实际调用；只要供应商按约提供可用容量，KAI 仍在交割完成后向供应商结算。未使用的 TPM 容量不退款、不结转，也不累积为可集中提取的 Token 余额。
- 超额使用：单次请求超过统一上下文上限时直接拒绝；聚合 TPM 超过所持容量上限 $C_{\text{max}}(N)$ 时，默认拒绝新增请求；合同另有约定的，可采用排队、降速或实时补购。
- 窗口边界：交割小时结束前已被系统接受的请求，按其所属交割小时继续完成；窗口结束后不再接受新请求，未使用容量归零。
- 供应不足：买方提供符合合约参数的足量请求时，供应商无法持续提供已售手数对应的 TPM，或容量内流量因供应商原因被限流，视为交割不足。TPM 履约按平台统一计量规则验证，供应商不得另设未披露的限流条件。KAI 可依规则协调备用供应商，额外成本和罚金由违约方承担。
- 重大不合格：错误模型、错误区域或严重质量偏差应按照重大交割失败处理。

GLM-5.2 示例

一笔 KAI 期算合约如何运行

GLM-5.2 官方资料将其定位为面向长程任务的旗舰文本模型，公开文档列示 1M 上下文、最大 128K 输出，并支持思考模式、流式输出、工具调用、上下文缓存和结构化输出。这些公开特征使其适合作为 KAI 多供应商模型服务品种的说明案例。

重要说明

以下合同参数、主体名称、价格和日期全部为 KAI 概念示例，不代表 GLM-5.2 官方服务条款或现实市场报价。

7.1 示例合约参数

项目	示例约定
指定模型及版本	GLM-5.2（以 KAI 品种规则登记的版本标识为准）
统一上下文上限	单次请求总上下文不超过 256K
输出权重 W	3
计量规则版本	KAI TPM 计量规则 v1.0（概念示例）
一手容量	1,000,000 TPM
指定交割小时	2026年9月18日 20:00至21:00（北京时间）
交割区域	东亚一区
超额处理方式	单次请求超过统一上下文上限时直接拒绝；聚合 TPM 超过所持容量时默认拒绝新增请求，合同另有约定的可排队、降速或实时补购
基本交付标准	可用性、系统或 API 错误率、首 Token 延迟、TPM 达成规则等按平台统一基本交付标准执行；不包括模型输出内容的正确性

7.2 参与者

身份	示例主体	在本案例中的行动
模型发布方	GLM-5.2 权利方	发布模型与版本信息；不必直接参与交易。

身份	示例主体	在本案例中的行动
KAI	市场平台	建立品种、组织交易、管理交割与市场信息发布。
容量供应商 A	东海智算（虚构）	登记 40 手并卖出其中 6 手。
容量供应商 B	北辰云（虚构）	登记 30 手并卖出其中 4 手。
备用供应商	南港云（虚构）	提供交割时的替代容量。
企业买方	星河电商（虚构）	为直播大促采购 10 手。
聚合商	KAI Partner（虚构）	为中小客户拆分其他容量。
结算机构	KAI Settlement（虚构）	管理预付资金、履约担保、交割结算与违约处置。

7.3 买方锁定未来成本

星河电商预计直播大促需要 10 手，合计 10,000,000 TPM 容量，于 2026 年 8 月买入，并在成交时向 KAI 全额预付。

项目	金额
买入价格	780 元/手
采购数量	10 手
最终服务价款	7,800 元

交割池后台记录东海智算提供 6 手、北辰云提供 4 手，但该分配不影响星河电商所持 10 手的权利和交割顺序。

KAI 在交割完成前按规则管理该笔预付资金；交割小时结束并确认供应商完成交付后，再按实际交付责任分别结算服务价款。该成交价即为本次采购的最终服务单价，届时市场价格变化不影响该价款，KAI 不因价格上涨或下跌向任何一方补偿价差。

这一安排使买方可以围绕确定业务事件，以成交价同时锁定预算和容量。

7.4 供应商锁定收入

供应商通过提前按合同价卖出容量，锁定未来收入和利用率，并取得交割完成后收取服务价款的权利。买方的预付资金在交割完成前由 KAI 按规则管理；供应商按约交付后，KAI 再向其结算。交割时不因届时市场价格上涨或下降而补收、返还或差额结算。供应商的经营重点由短期猜价转向稳定交付和成本管理。

7.5 买方需求变化

若星河电商在活动前发现只需要 9 手，可在关闸前出售 1 手（1,000,000 TPM）。受让方按转让成交价向 KAI 全额支付；转让登记生效后，KAI 按规则向星河电商结算转让价款。该价格即为受让方对应 1 手的最终服务价款；供应商对初始服务价款的权利及原交付义务不变，初始服务价款仍在交割完成后由 KAI 结算，KAI 不补偿任何价差。若活动临时增加 TPM 需求，也可以补购。交割时，即使其实际 TPM 峰值低于所持 9 手对应的 9,000,000 TPM，未使用部分也不退款、不结转，因为供应商已经按照其持有手数预留了完整处理容量。

7.6 供应商故障

假设北辰云在交割小时内出现部分交付不足，KAI 可暂缓向其结算对应服务价款，并依规则协调南港云参与替代交付。替代价格高于原合同价格的差额、违约金和相关处置成本，由违约供应商按照规则承担；KAI 的协调不构成对供应商债务或替代成功的兜底保证。

7.7 不同身份如何获得价值

身份	本案例中的价值
星河电商	避免高峰容量不足，并把 10 手的成本锁定在预算内。
东海智算与北辰云	提前确认收入与利用率，为资源安排提供依据。
南港云	通过备用容量获得更高的平衡市场收入。
模型发布方	扩大 GLM-5.2 企业服务生态和市场可见度。
聚合商	将标准大额容量转换为适合中小客户的产品。
KAI	通过标准、交易和交付治理降低多方协作成本。

定价与市场结构

价格形成、期限结构与流动性组织

8.1 一手价格代表什么

小时价格不是简单的芯片租赁费。它综合反映模型服务的直接成本、区域和网络约束、基本交付标准、备用安排、时间稀缺性以及市场流动性。最终价格体现的是：为确保某个模型在某一时段达到合同标准，市场需要放弃多少其他可销售能力。

价格组成	影响方向
基础服务成本	模型越大、基本交付标准越高，通常价格越高。
时段稀缺性	工作日高峰、活动时段和已知事件可能形成溢价。
区域约束	网络和本地资源紧张会形成区域差价。
期限与不确定性	交割越远，需求预测、模型更新和成本变化的不确定性越大。
市场流动性	参与者少、转让困难的品种需要更高风险补偿。

8.2 期限结构

KAI 可以形成从小时前、日前、周前到月前的价格曲线。买方据此判断是提前锁定还是保留弹性，供应商据此判断未来扩容和容量安排。期限结构还可以显示市场对模型版本生命周期的预期：若新版本即将发布，旧版本远期价格可能提前下降。

8.3 初期市场组织

市场启动阶段不宜一次挂牌大量模型、区域和基本交付标准组合。过多品种会分散交易需求。更现实的方案是选择一个模型、一个区域、一套统一基本交付标准和少数高需求时段，由供应商优先发布日前或周前报价，并根据真实成交逐步形成基准价格，再逐步增加可售时段和多小时组合。

8.4 多小时组合

企业往往需要连续四小时、工作时段或整日容量。KAI 可以允许买方以一个订单购买“条带”，后台对应多个小时的交割义务。这样既保持小时价格的准确性，也减少企业逐小时采购的操作负担。

8.5 价格指数

当真实成交和交割数据积累后，KAI 可以发布模型容量基准指数、峰谷指数、区域价差和交付标准价差。指数有助于企业预算、供应商报价、长期合同重定价和产业研究。指数治理必须避免被少量关联交易操纵，并公开说明样本、异常处理和修订规则。

8.6 流动性不是交易量的同义词

对 KAI 而言，优质流动性意味着企业能够以合理价差完成真实采购，供应商能够稳定出售真实容量，临近交割仍存在替代能力。仅由短期交易制造的大量成交，如果不能支持实物服务交割，并不能提高产品价值。

商业模式

KAI 的收入来源与可持续经营逻辑

9.1 收入结构

收入来源	付费方	价值依据
交易与转让服务费	买方、卖方或经纪商	订单撮合、合同管理和市场信息。
交割与结算服务费	交割参与者	交割准备、资金结算、替代采购和违约处理。
供应商评估与年度复核费	容量供应商	能力评估、持续评价和品牌信任。
市场数据与指数订阅	供应商、投资机构、研究机构	历史价格、期限曲线和供需数据。
流动性与风险服务	供应商、买方	备用容量、信用增级和特定服务保障。
模型生态合作	模型发布方或合作伙伴	品牌品种、联合市场和收入分成。

9.2 收入原则

- 收入应与真实采购、真实交割和服务质量增长一致，而不是只依赖短期交易次数。
- 供应商准入费用不应导致“付费即通过”，资格判断必须独立。
- 平台若提供备用容量或流动性支持，应明确收费、优先级和利益冲突。
- 对早期锚定客户可提供费率优惠，但市场规则和交割权利应保持一致。

9.3 关键成本

成本类别	说明
市场运营	品种设计、会员服务、订单与合同管理、客户支持。
资格与评估	供应商评估、持续评价、争议复核。
交割保障	备用供应商合作、违约处置和应急协调。
信用风险资本	担保、违约基金或与第三方金融机构合作的成本。
生态建设	吸引锚定买方、供应商、聚合商和模型合作伙伴。

9.4 单位经济的核心驱动

KAI 的单位经济取决于四项因素：真实交割规模、重复采购率、每个品种的流动性密度以及违约损失率。过早扩展大量低活跃品种会提高运营成本并降低成交密度；过低担保会放大违约损失；过高收费又会使企业回到双边采购。因此，市场规模化应优先提高单一品种的深度，而不是追求品种数量。

治理与风险管理

交付、信用、流动性、集中度与市场秩序

10.1 治理目标

KAI 的治理目标不是消除所有风险，而是让风险在合同中可识别、在价格中可反映、在责任上可归属，并通过担保、替代和限制避免单一失败扩散为系统性问题。

风险	表现	主要治理方式
交付风险	供应商无法提供全部容量。	真实容量登记、履约担保、备用供应商、违约赔付。
质量风险	服务虽然可用，但模型版本不符或未达到基本交付标准。	明确标准、独立复核、重大不合格零容忍。
信用风险	供应商不能按约交付或承担替代成本。	预付资金管理、供应商履约担保、逐笔资金核验和备用供应商。
流动性风险	持仓难以在交割前转让。	限制品种数量、锚定参与者、供应商报价和流动性计划。
集中度风险	单一模型方或供应商控制大部分交割量。	供应商上限、持仓限额、关联账户识别。
版本风险	模型升级使旧品种需求骤降。	新旧版本分开挂牌、透明退市和迁移安排。
基差风险	标准合约与买方真实业务需求不完全一致。	明确基本交付标准、适当的品种选择和定制补充合同。
平台利益冲突	KAI 利用规则或数据偏向关联方。	业务隔离、公开规则、独立治理和外部审查。

10.2 违约处置原则

1. 服务优先：对买方最有价值的补救通常是及时替代容量，而不是事后退款。
2. 违约无利可图：供应商故意不交割并转售高价现货，不应获得经济收益。
3. 损失有边界：标准合同应明确直接替代成本、固定补偿和责任上限。
4. 分层处置：先暂缓结算违约方对应服务价款并使用其履约担保，再使用违约基金或第三方信用增级。
5. 持续评价：违约记录影响供应商额度、担保比例和后续准入。

10.3 市场诚信

KAI 应公开品种规则、交割标准、收费、供应商资格原则和异常处置流程。成交数据应区分真实外部交易与关联交易，价格指数应排除明显异常样本。大额持仓、供应商自买自卖和临近交割集中持仓需要更高透明度。

10.4 模型更新与退市

模型市场迭代快。KAI 应提前公布新品种挂牌、旧品种停止新增月份、最后交割日和迁移选择。除非出现严重技术或安全事件，已成交的旧版本合约不应被单方面换成新模型。

10.5 买方保护

企业买方应清楚理解未使用不退款、基本交付标准及其适用边界、超额处理方式及可能产生的费用、模型输出风险和违约补偿上限。对缺乏专业采购能力的中小客户，可通过聚合商或标准服务套餐降低复杂度。

市场进入与发展路线

从试点到规模化市场的阶段安排

11.1 首批场景选择

KAI 应选择需求时间明确、容量规模较大、业务可以量化且企业愿意为确定性付费的场景。

场景	为何适合
电商与直播大促	活动时间确定、峰值明显、容量不足会直接影响客户体验。
客服高峰	节假日、促销会形成可预测或突发需求。
代码代理集中运行	企业可安排夜间或项目冲刺时段，连续容量价值高。
批量内容与研究任务	可在非高峰时段执行，有利于形成峰谷价格和需求迁移。
教育与考试服务	课程、报名和考试时段明确，对稳定性要求高。
企业内部日终处理	周期稳定，适合作为基础负载锚定需求。
金融研究与风控批处理	盘前、盘后、财报季和定期风控任务时间集中，对处理时效和容量稳定性要求较高。
游戏上线与大型活动	新服开放、版本更新和游戏内活动时间明确，短时调用峰值明显。
新闻、赛事与媒体生产	重大会议、体育赛事和定时发布活动会产生集中摘要、翻译、审核和内容生成需求。
AI应用发布与营销活动	新产品发布、集中投放或用户拉新可能在确定时段形成模型调用高峰。
企业文档与知识处理	财务结算、合同审查、档案整理和知识库更新可集中安排，适合采购非高峰时段容量。

11.2 首批品种选择

1. 选择一个产品特征清晰、企业认知高、存在多家潜在供应商的模型。
2. 只设置一个主要区域和一套统一基本交付标准，减少流动性分散。
3. 由供应商根据其实际可交付容量，优先对日前、周前及其他可售交割小时发布报价。
4. 以连续四小时、工作时段等组合满足企业采购习惯。
5. 采用买方向平台全额预付、供应商履约担保和实物服务交割，不在早期引入高杠杆。

11.3 四阶段路线

阶段	参考时间	主要任务	关键里程碑
阶段 0：联合设计	0至6个月	与模型方、供应商和锚定买方共同确定标准、合同和试点时段。	签署合作意向；形成首个品种和交割规则。
阶段 1：期算	6至12个月	开展买方向平台全额预付、供应商履约担保的 B2B 期算预订、分配与有限转让。	稳定完成真实小时交割；建立供应商评分。
阶段 2：日前与平衡市场	12至24个月	形成公开日前价格和临近交割补购机制。	建立可信价格指数和替代容量网络。
阶段 3：标准期算与多区域	24至36个月	扩展模型、区域和多小时组合，引入更完善的信用安排。	提高重复采购、流动性和跨供应商份额。

11.4 锚定参与者策略

KAI 应同时获得供应端和需求端锚定。需求端需要至少数家具有周期性大额需求的企业；供应端需要至少两到三家可相互替代的交割机构。只有单一供应商时，市场更像其预售渠道；只有买方而缺少备用供应商时，交割保障不足。

11.5 成功指标

维度	建议指标
真实需求	交割容量中用于真实企业业务的比例、重复采购率。
交付质量	按时足额交割率、替代成功率、重大不合格次数。
市场效率	买卖价差、转让完成率、临近交割可用容量。
供应商生态	合格供应商数量、单一供应商占比、区域覆盖。
客户价值	相对临时采购的成本稳定性、容量中断减少、预算偏差。
风险	违约损失率、担保覆盖率、关联交易和异常交易比例。
商业可持续	每手收入、客户获取成本、交割服务成本、毛利和留存。

竞争壁垒与网络效应

KAI 如何形成长期基础设施价值

12.1 标准壁垒

市场参与者一旦围绕 KAI 的品种定义、合同语言、供应商资格和价格指数建立采购流程，切换成本将不仅来自软件，也来自内部预算、合同管理、风控和供应商管理体系。被行业接受的标准本身就是基础设施。

12.2 供需网络效应

更多合格供应商带来更可靠交付和更有竞争力的价格，从而吸引更多企业买方；更多稳定买方又提高供应商提前登记容量的意愿。供需两端相互增强，是 KAI 最核心的网络效应。

12.3 数据网络效应

随着交割积累，KAI 将形成不同模型、时段、区域和基本交付标准下的价格、需求、违约和替代记录。这些数据可以改进品种设计、担保要求、供应商额度和企业采购计划。数据价值来自真实交付，而非仅来自报价。

12.4 信用与治理壁垒

企业愿意把关键业务交给 KAI，取决于平台是否能在故障时组织替代、在争议时独立判断、在供应商集中时保持中立。长期稳定的治理记录比短期补贴更难复制。

12.5 三个增长飞轮

飞轮	循环
流动性飞轮	更多买方 → 更多供应商 → 更窄价差 → 更高采购意愿。
交付飞轮	更多交割数据 → 更准确风控 → 更低违约成本 → 更强信任。
生态飞轮	标准品种 → 聚合、保险、指数和融资服务 → 更多使用场景。

12.6 潜在竞争者

竞争者	优势	KAI 的差异化方向
大型云平台	拥有资源、客户和交付能力。	跨供应商中立、模型级标准和统一价格。

竞争者	优势	KAI 的差异化方向
模型官方 API	模型控制力和品牌信任强。	多运营商容量、转让和替代交付。
算力租赁平台	底层资源供应丰富。	从硬件单位转向企业可直接采购的模型服务单位。
传统交易或大宗平台	市场、清算和运营经验。	对模型服务、版本和企业 AI 采购的专业理解。
大型系统集成商	客户关系和交付能力。	开放市场、透明价格和标准化跨客户流动性。

结论

KAI 的战略判断与核心原则

AI 服务市场的下一阶段，不仅是模型能力提升和调用价格下降，也包括容量如何被计划、承诺、转移和定价。企业关键业务需要的不是抽象算力，而是在确定交割小时、指定模型和交割区域内，符合基本交付标准的可用能力。

KAI 将这种未来容量产品称为“期算”，采用第 3.2 节定义的加权 TPM 作为基础容量计量指标，并以 $\text{TPM} \cdot \text{h}$ 表示容量与持续时间；一手对应一个交割小时内每个计量窗口持续可用的 1,000,000 TPM 容量上限。这一口径以统一标准连接企业需求与多家供应商。其产品价值体现在三个层次：在采购层面提供容量和预算确定性；在市场层面形成价格发现与资源配置；在产业层面把模型、云、数据中心和企业应用连接成可持续服务生态。

KAI 的四项战略原则

1. 以真实企业需求为起点，而不是以交易频率为起点。
2. 以实物服务交割为锚，确保价格最终对应可使用的模型能力。
3. 以少数高质量品种建立流动性，再逐步扩展模型和区域。
4. 以买方向平台全额预付、供应商履约担保、交割后结算、备用交付和独立治理建立信用。

最终判断

KAI 的长期价值不在于把算力包装成金融概念，而在于让模型容量成为可理解、可比较、可承诺、可转让并可追责的企业基础资源。

附录：术语表

用于产业与采购沟通

术语	解释
TPM	Tokens Per Minute，每分钟加权 Token 负载；按 $TPM = I + W \times O$ 计算。期算按小时交割，一手为 1,000,000 TPM。
输出权重 W	用于将输出 Token 折算为统一 TPM 负载的系数，由品种规则确定并随计量规则版本固定，合约存续期间不追溯调整。
首 Token 延迟	从平台确认接收符合合约参数的请求，到返回首个输出 Token 的时间；阈值与统计口径由品种规则规定。
基础负载	稳定、可预测并持续存在的模型服务需求。
峰值负载	在特定活动或时段短期显著增加的需求。
交割关闸	停止转让并锁定账户可调用容量与供应商交付责任的时间。
实物交割	以实际模型服务能力完成到期义务。
备用容量	在主供应商失败时用于替代交付的额外能力；买方需求超额时，只有合同另有约定或完成实时补购后方可调用。
替代采购	供应商违约时，平台可依规则协调其他供应商提供服务。
基差风险	标准合约与企业实际需求之间不完全匹配造成的风险。
流动性	在不显著影响价格的情况下完成采购或转让的能力。
持仓	参与者尚未平仓或完成交割的合约数量。
套期保值	利用未来合约降低实际采购或销售价格波动。
一手	指定交割小时内每个计量窗口持续可用的 1,000,000 TPM 容量上限，是标准交易单位。
供应商集中度	少数供应商占可交割容量的比例。
模型生命周期	模型从发布、采用、升级到停止服务的过程。